TECHNISCHE PRÄSENTATION

Lumelle AI

Lokale KI ohne Internet



Varvara Surnova

DIE AUFGABE

Ein Assistent ohne Cloud



PROBLEM

Daten im Netz



ZIEL

KI auf dem PC



ERGEBNIS

Läuft offline

FUNKTIONEN

Was Lumelle kann



Chat



Write



Translate



Slides



Learn



Bilder



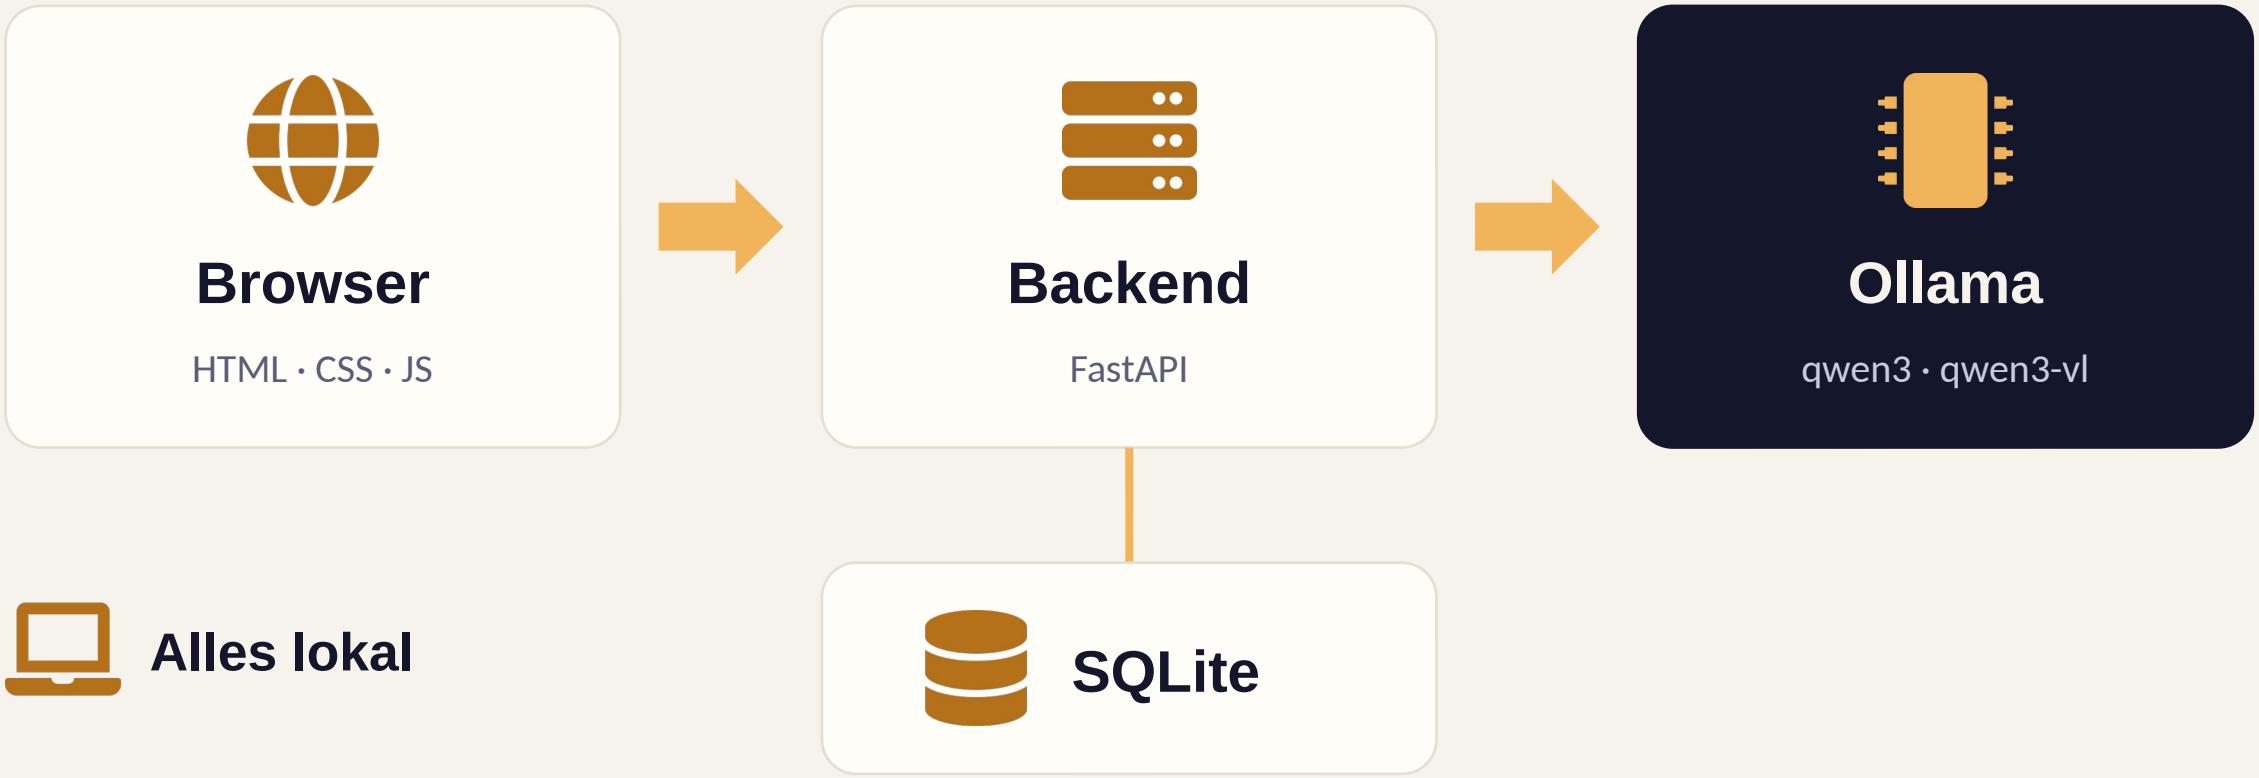
Verlauf



5 Sprachen

ARCHITEKTUR

Drei Schichten, ein Computer



STACK

Technologien

Qwen3 8B
Text

Qwen3-VL 8B
Bilder

Ollama
Modell-Laufzeit

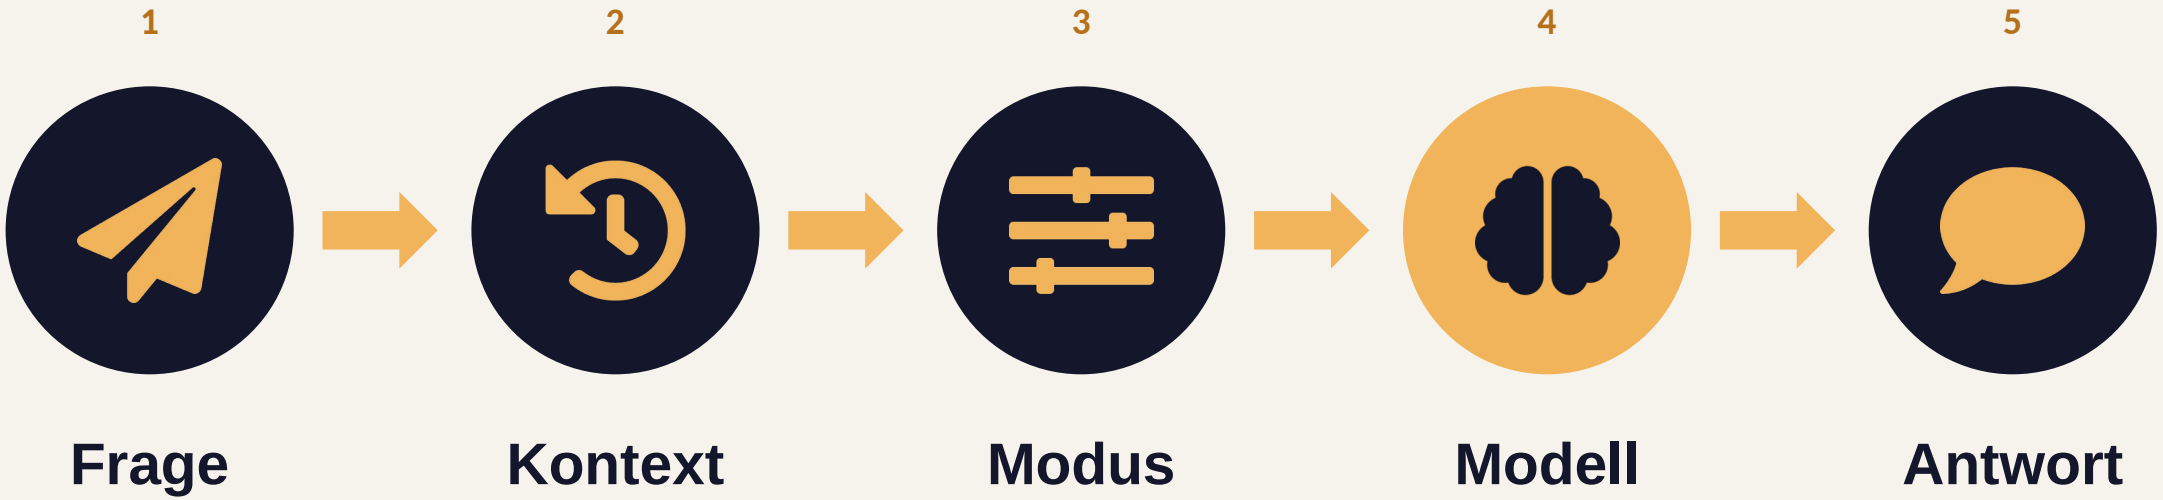
FastAPI
Backend · python-pptx

SQLite
Verlauf

HTML · CSS · JS
Oberfläche

ABLAUF EINER ANFRAGE

Der Weg einer Nachricht



letzte 20 Nachrichten · Modus-Prompt · qwen3 oder qwen3-vl

MODELL-EINSTELLUNGEN

Temperatur je Modus

Chat	Write	Translate	Slides	Learn
0.4	0.7	0.1	0.5	0.4
präzise	lebendig	genau	strukturiert	ausgewogen



`think` — vor der Antwort nachdenken

Zwei Tabellen in SQLite

chats

- id
- title
- mode
- created_at

1:N

messages

- id
- chat_id → chats
- role
- content
- images
- created_at

REST API

8 Endpunkte

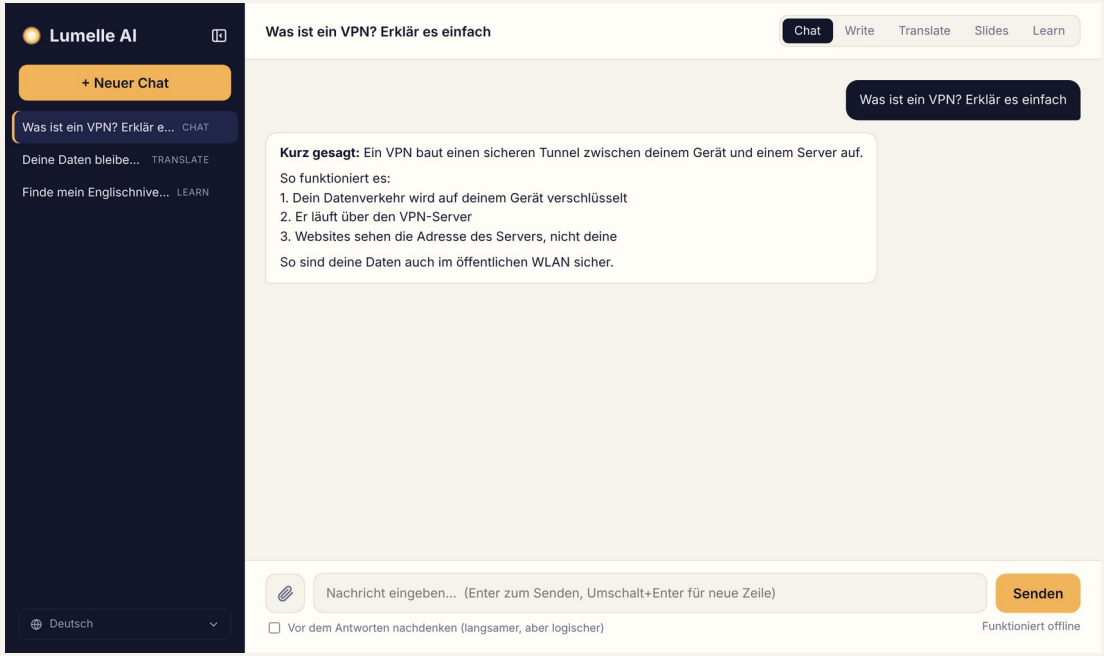
POST	/ask
POST	/chats/{id}/ask
POST	/chats
PATCH	/chats/{id}
GET	/chats
DELETE	/chats/{id}
GET	/chats/{id}
GET	/decks/{file}

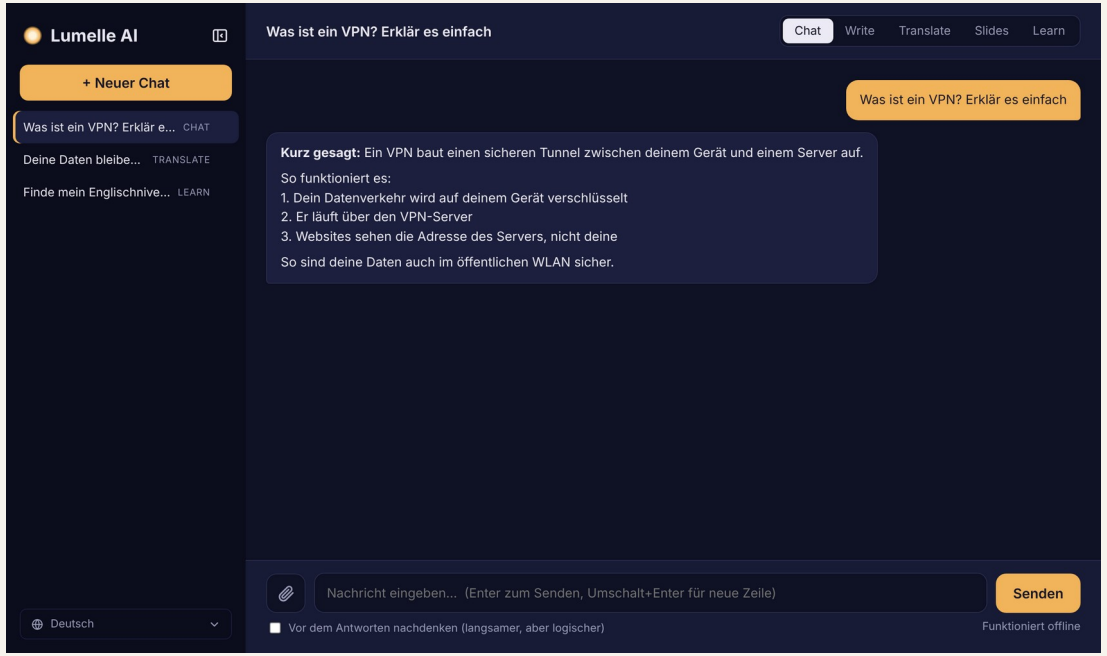


/docs

OBERFLÄCHE

Helles und dunkles Design





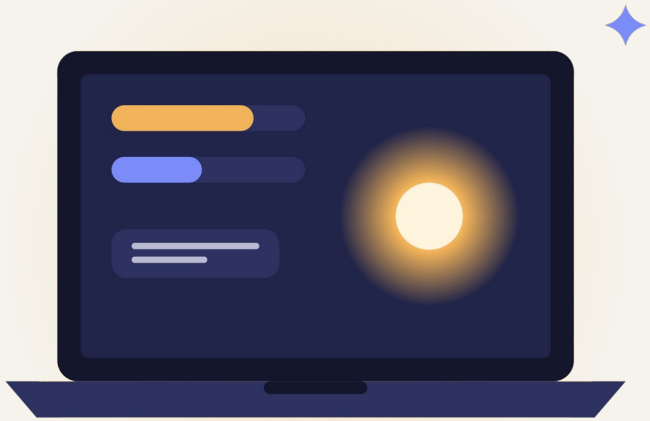
ANFORDERUNGEN

Worauf es läuft

16 GB
RAM

11 GB
auf der Platte

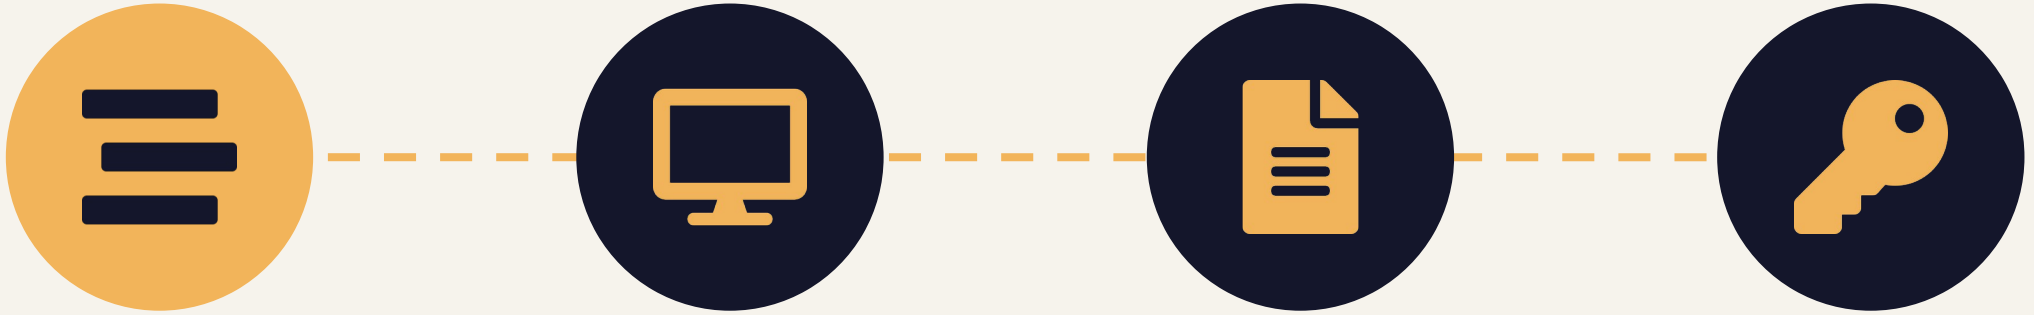
0
Netzwerkanfragen



Windows · macOS · Linux

ROADMAP

Pläne



Streaming

Desktop-App

Eigene Dokumente

Passwort



Danke für Ihre Aufmerksamkeit!

Fragen?