PRÉSENTATION TECHNIQUE

Lumelle AI

IA locale, sans internet



Varvara Surnova

LA TÂCHE

Un assistant sans le cloud



PROBLÈME

Données exposées



OBJECTIF

L’IA sur le PC



RÉSULTAT

Hors ligne

FONCTIONNALITÉS

Ce que Lumelle sait faire



Chat



Write



Translate



Slides



Learn



Images



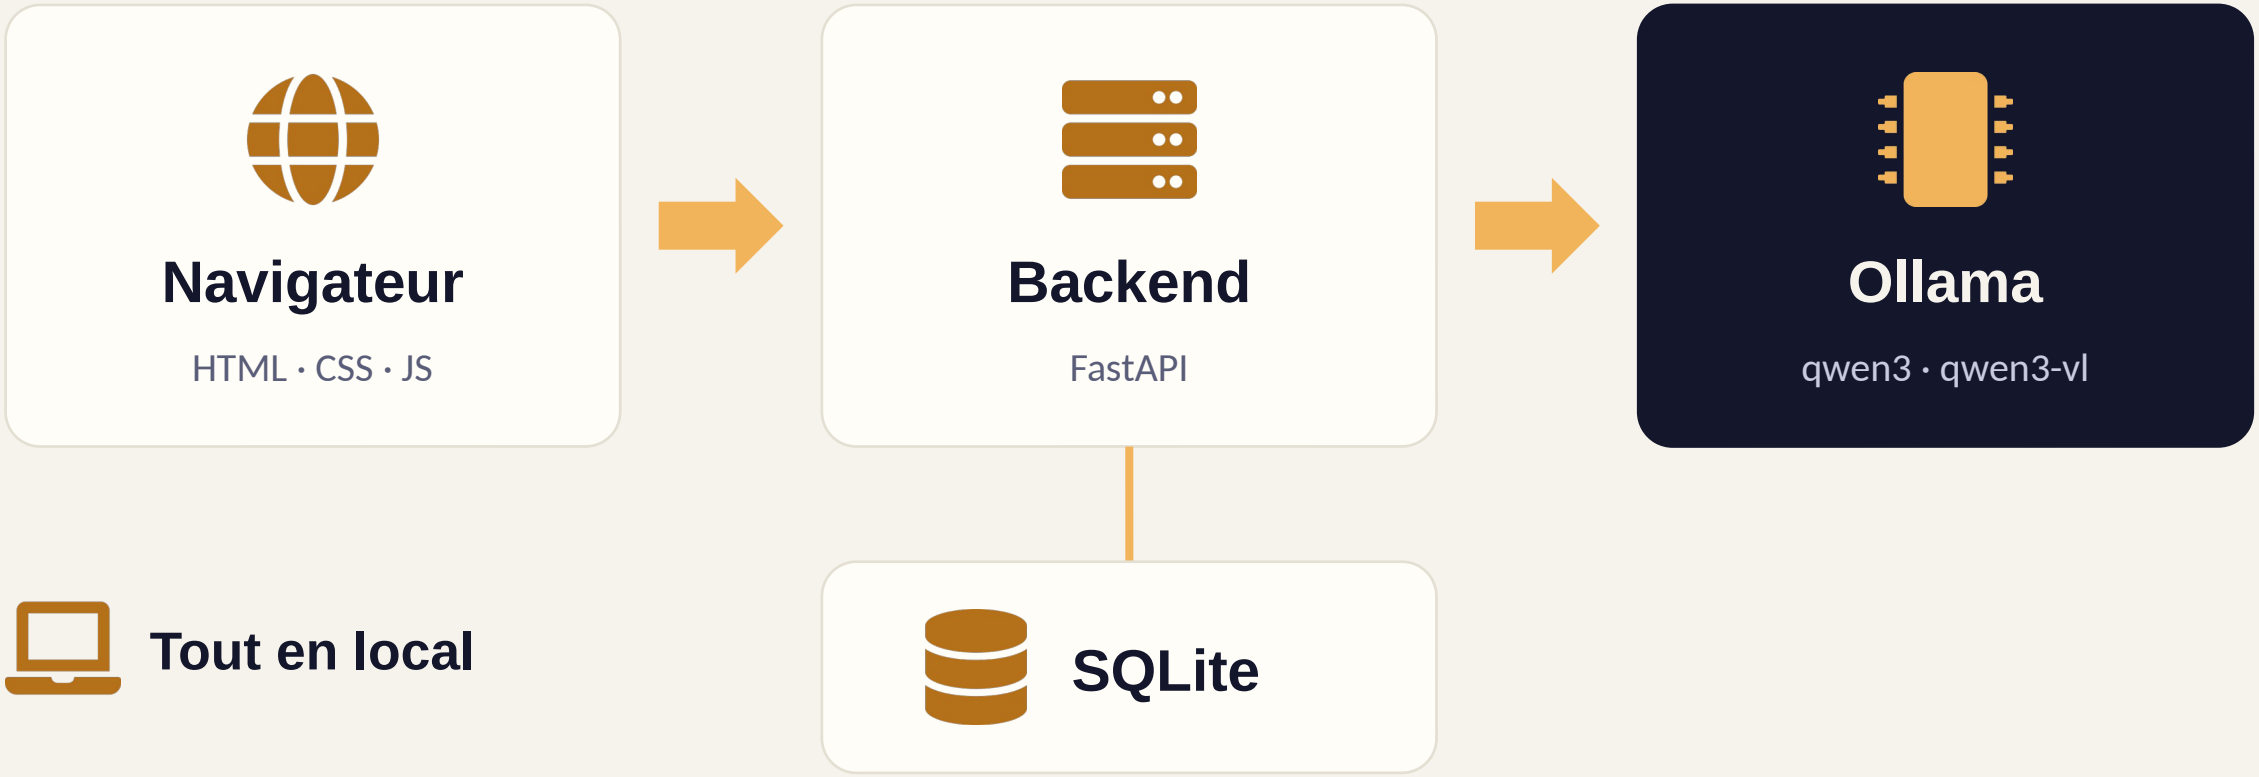
Historique



5 langues

ARCHITECTURE

Trois couches, un ordinateur



STACK

Technologies



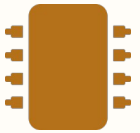
Qwen3 8B

texte



Qwen3-VL 8B

images



Ollama

exécution des modèles



FastAPI

backend · python-pptx



SQLite

historique

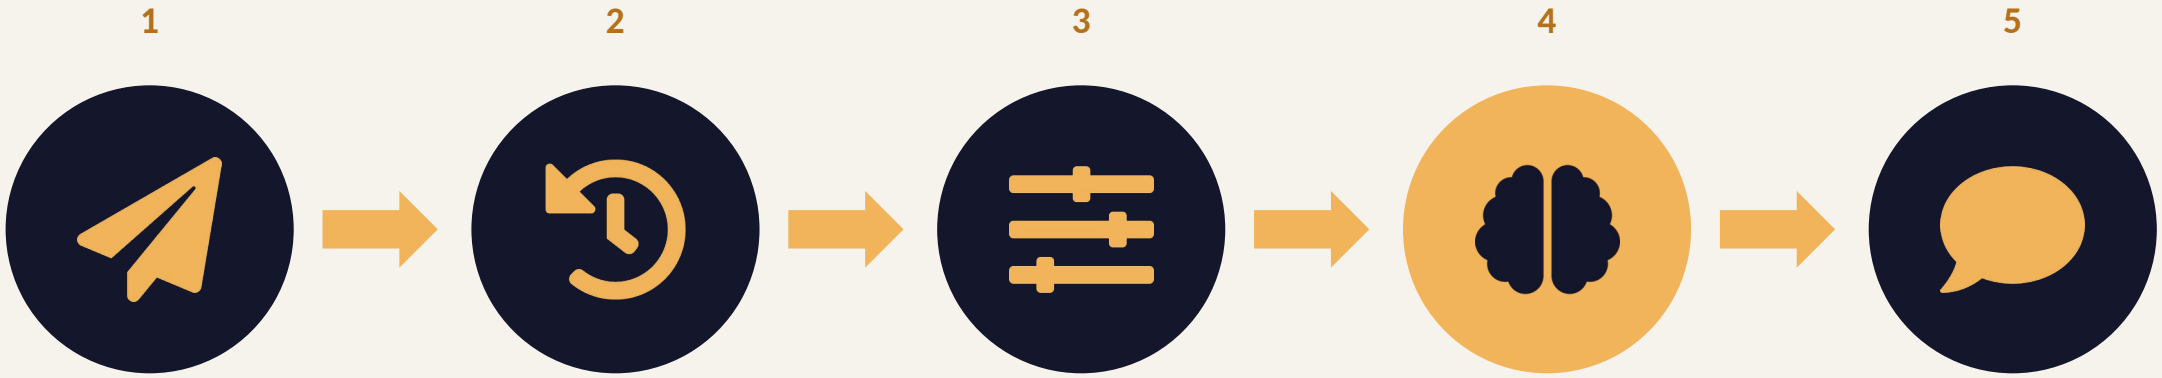


HTML · CSS · JS

interface

TRAITEMENT D'UNE REQUÊTE

Le trajet d'un message



20 derniers messages · prompt du mode · qwen3 ou qwen3-vl

RÉGLAGES DU MODÈLE

Température par mode

Chat	Write	Translate	Slides	Learn
0.4	0.7	0.1	0.5	0.4
précis	vivant	exact	structuré	équilibré

`think` — réfléchir avant de répondre

Deux tables dans SQLite

chats

- id
- title
- mode
- created_at

1:N

messages

- id
- chat_id → chats
- role
- content
- images
- created_at

REST API

8 endpoints

POST	/ask
POST	/chats/{id}/ask
POST	/chats
PATCH	/chats/{id}
GET	/chats
DELETE	/chats/{id}
GET	/chats/{id}
GET	/decks/{file}

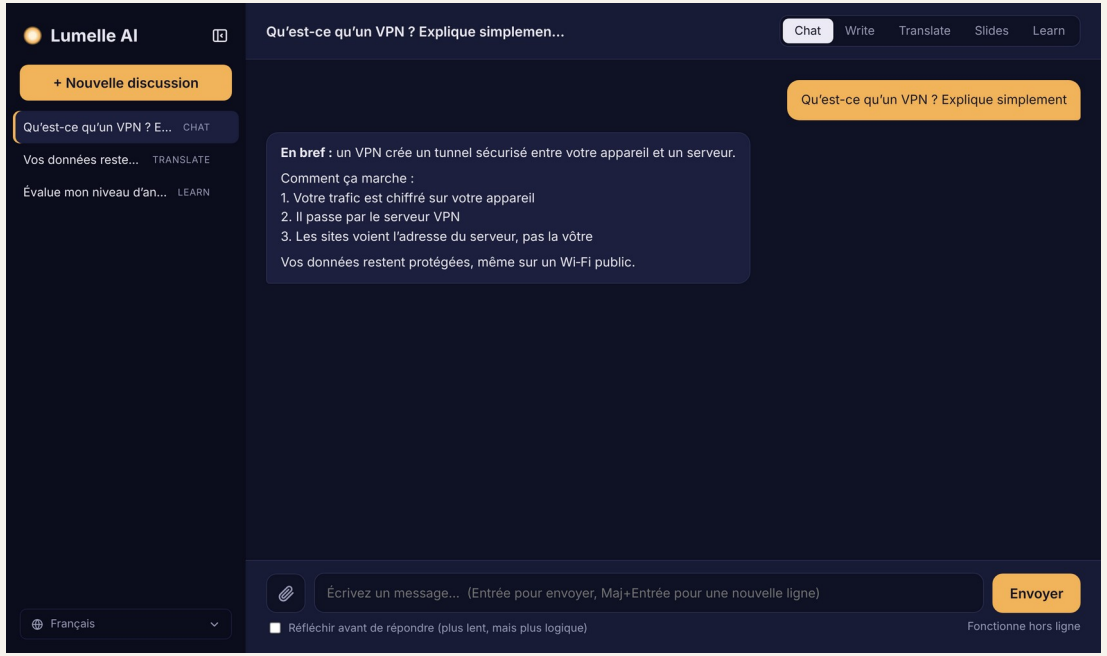


/docs

INTERFACE

Thème clair et thème sombre





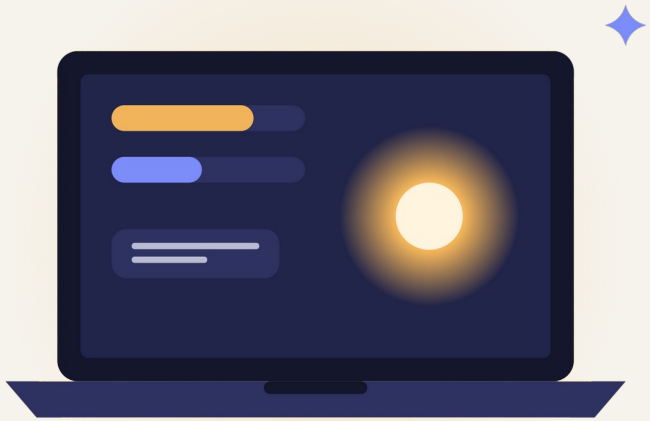
CONFIGURATION

Sur quoi il tourne

16 Go
RAM

11 Go
sur le disque

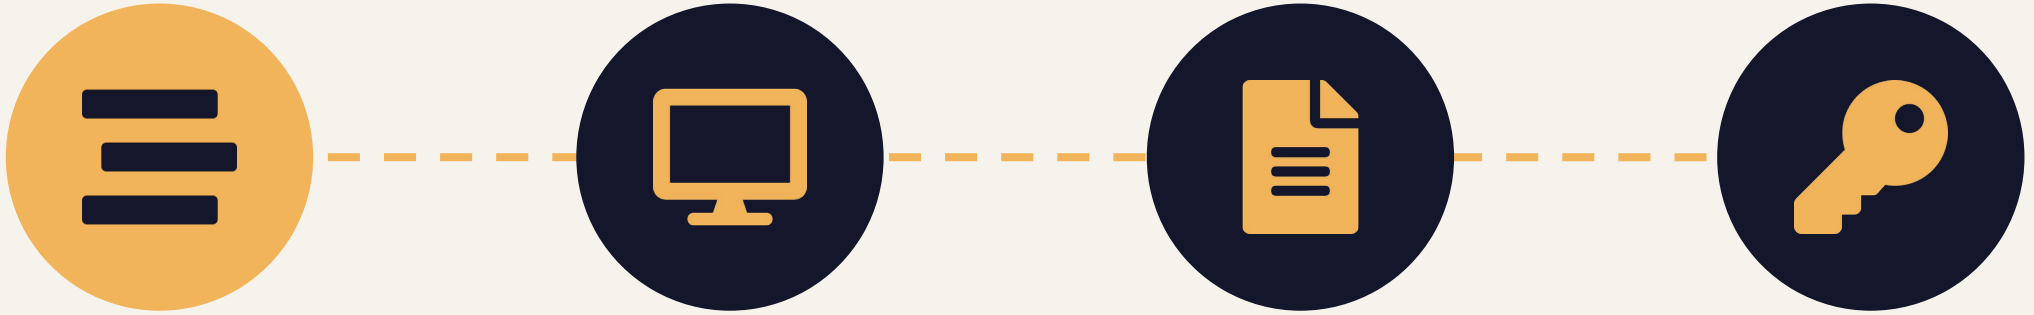
0
requête réseau



Windows · macOS · Linux

FEUILLE DE ROUTE

Projets



Streaming

Appli de bureau

Vos documents

Mot de passe



Merci de votre attention !

Des questions ?