ТЕХНИЧЕСКАЯ ПРЕЗЕНТАЦИЯ

# Lumo AI

Локальный ИИ-ассистент, который работает без интернета



Сурнова Варвара

ЗАДАЧА

# Ассистент без облачного сервера

## Проблема

Облачные ассистенты отправляют переписку на внешние серверы, не работают без сети и требуют подписки.

## Цель

Запустить языковую модель прямо на ноутбуке и дать к ней удобный интерфейс с историей чатов.

## Результат

Рабочее веб-приложение: три режима, сохранение чатов, полностью офлайн на MacBook Air M-серии.

ВОЗМОЖНОСТИ

# Что умеет Lumo



## Chat

Структурированные ответы: сначала коротко, потом по шагам



## Write

Письма, посты и эссе с заданным тоном и длиной



## Translate

Русский ↔ английский, только перевод



## История чатов

Чаты сохраняются, модель помнит 20 последних сообщений



## Режим «Думать»

Модель рассуждает перед ответом: дольше, но логичнее

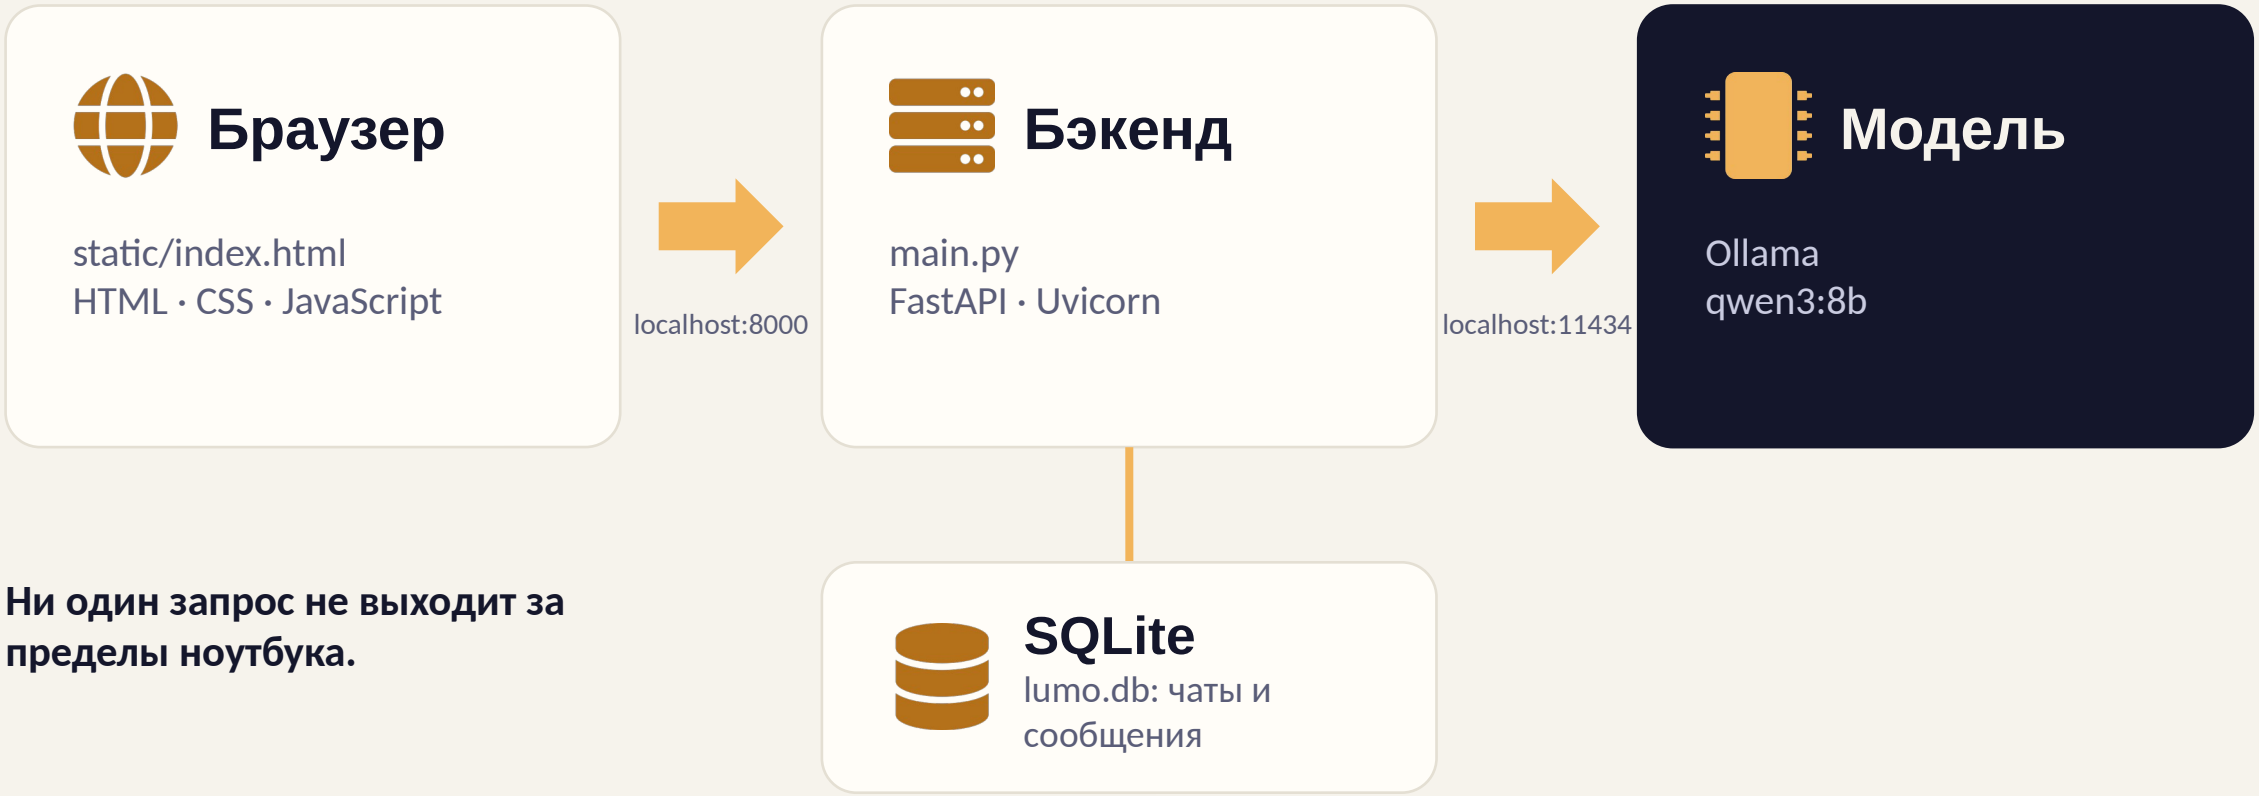


## Офлайн

Ни одного внешнего запроса, даже шрифты системные

АРХИТЕКТУРА

# Три слоя, и все на одном компьютере




**Ни один запрос не выходит за пределы ноутбука.**

СТЕК

# Технологии

| Слой | Технология | Зачем |
|---|---|---|
| Языковая модель | Qwen3 8B | Хорошо понимает русский и английский, помещается в 16 ГБ памяти (≈5 ГБ на диске) |
| Запуск модели | Ollama | Локальный сервер моделей с простым HTTP API, оптимизирован под Apple Silicon |
| Бэкенд | Python, FastAPI, Uvicorn | Асинхронный API, автоматическая документация /docs, проверка данных через Pydantic |
| HTTP-клиент | httpx | Асинхронные запросы к Ollama с таймаутом и обработкой ошибок |
| Хранилище | SQLite | Встроен в Python, не нужен отдельный сервер базы данных |
| Интерфейс | HTML, CSS, JavaScript | Без фреймворков и сборки, без внешних CDN: работает офлайн |

ОБРАБОТКА ЗАПРОСА

# Путь одного сообщения

**1 Интерфейс**

отправляет POST /chats/{id}/ask с текстом и флагом think

**2 Бэкенд**

загружает из SQLite последние 20 сообщений чата

**3 Бэкенд**

добавляет системный промпт и температуру режима

**4 Ollama**

генерирует ответ моделью qwen3:8b

**5 Бэкенд**

сохраняет вопрос и ответ, задаёт название чата

**6 Интерфейс**

показывает ответ с форматированием Markdown

НАСТРОЙКА МОДЕЛИ

# У каждого режима свой промпт и температура

| Режим | Главное в системном промпте | Температура |
|---|---|---|
| Chat | Отвечать на языке пользователя, сначала коротко, потом по шагам; не выдумывать факты | 0.4 |
| Write | Соблюдать формат, тон и длину; возвращать только готовый текст | 0.7 |
| Translate | Русский → английский, остальное → русский; только перевод | 0.1 |

Температура: ниже значит точнее и предсказуемее, выше значит разнообразнее.



**Параметр think.** Qwen3 умеет рассуждать перед ответом. По умолчанию это выключено ради скорости, а включается галочкой «Думать» в интерфейсе.

# Две таблицы в SQLite

**chats**

```
id  INTEGER  PK
title  TEXT
mode  TEXT
created_at  TEXT
```



1:N

**messages**

```
id  INTEGER  PK
chat_id  →  chats.id
role  user | assistant
content  TEXT
created_at  TEXT
```

Файл lumo.db лежит в папке проекта и не попадает в Git (.gitignore). Название чата задаётся по первым 40 символам первого сообщения.

REST API

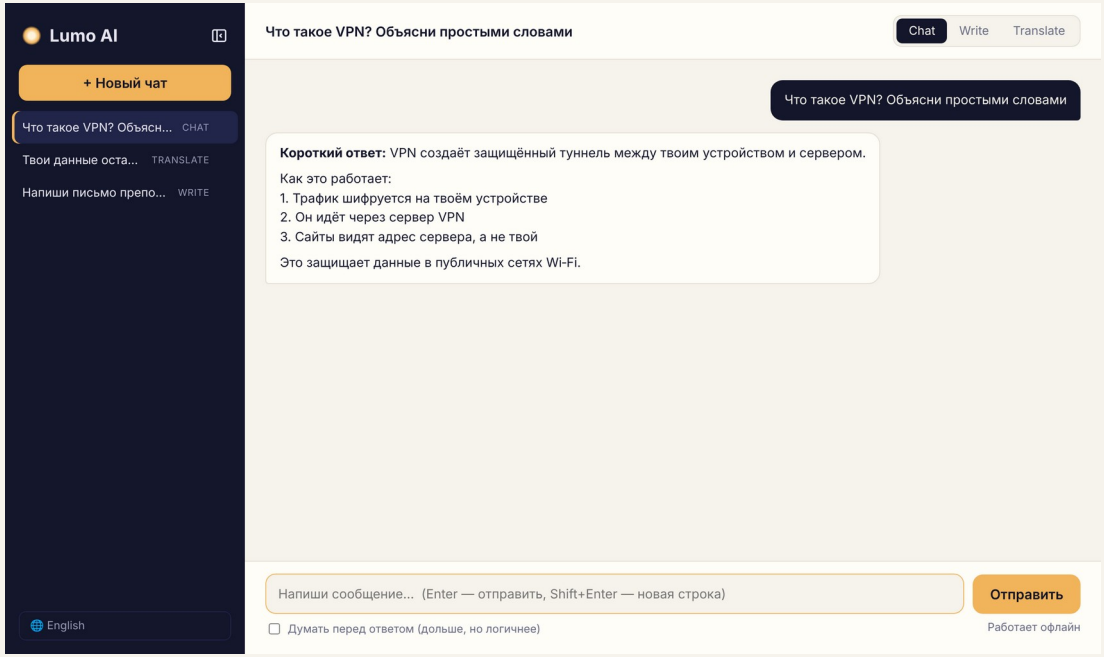
# Эндпоинты бэкенда

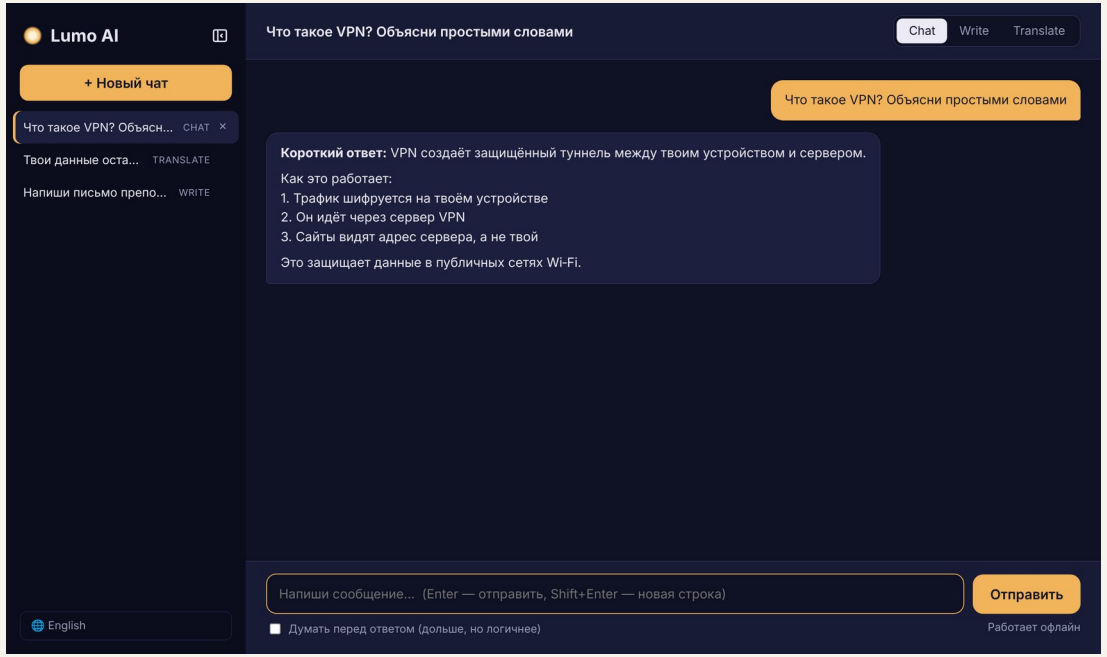
| Метод | Путь | Назначение |
|---|---|---|
| POST | /ask | Разовый вопрос без сохранения |
| POST | /chats | Создать чат с выбранным режимом |
| GET | /chats | Список чатов |
| GET | /chats/{id} | Чат со всей историей |
| POST | /chats/{id}/ask | Сообщение в чат с учётом контекста |
| PATCH | /chats/{id} | Сменить режим чата |
| DELETE | /chats/{id} | Удалить чат |

Интерактивная документация генерируется автоматически: http://127.0.0.1:8000/docs

ИНТЕРФЕЙС

# Светлая и тёмная тема




- Список чатов и переключение между ними
- Переключатель режимов Chat / Write / Translate
- Markdown в ответах: списки, жирный текст, код
- Тёмная тема и мобильная вёрстка

ТРЕБОВАНИЯ

# На чём работает

**16 ГБ**

оперативной памяти: тестовый MacBook Air

**≈5 ГБ**

занимает модель qwen3:8b на диске

**0**

внешних запросов во время работы

macOS на Apple Silicon, Python 3.9+, Ollama. Интернет нужен только для установки модели и библиотек.

РАЗВИТИЕ

# Планы



## Потоковые ответы

Текст появляется по словам

Следующий шаг



## Mac-приложение

Упаковка в Tauri



## Свои документы

Локальный RAG по PDF и DOCX



## Пароль

Доступ с других устройств



# Спасибо за внимание!

Вопросы?