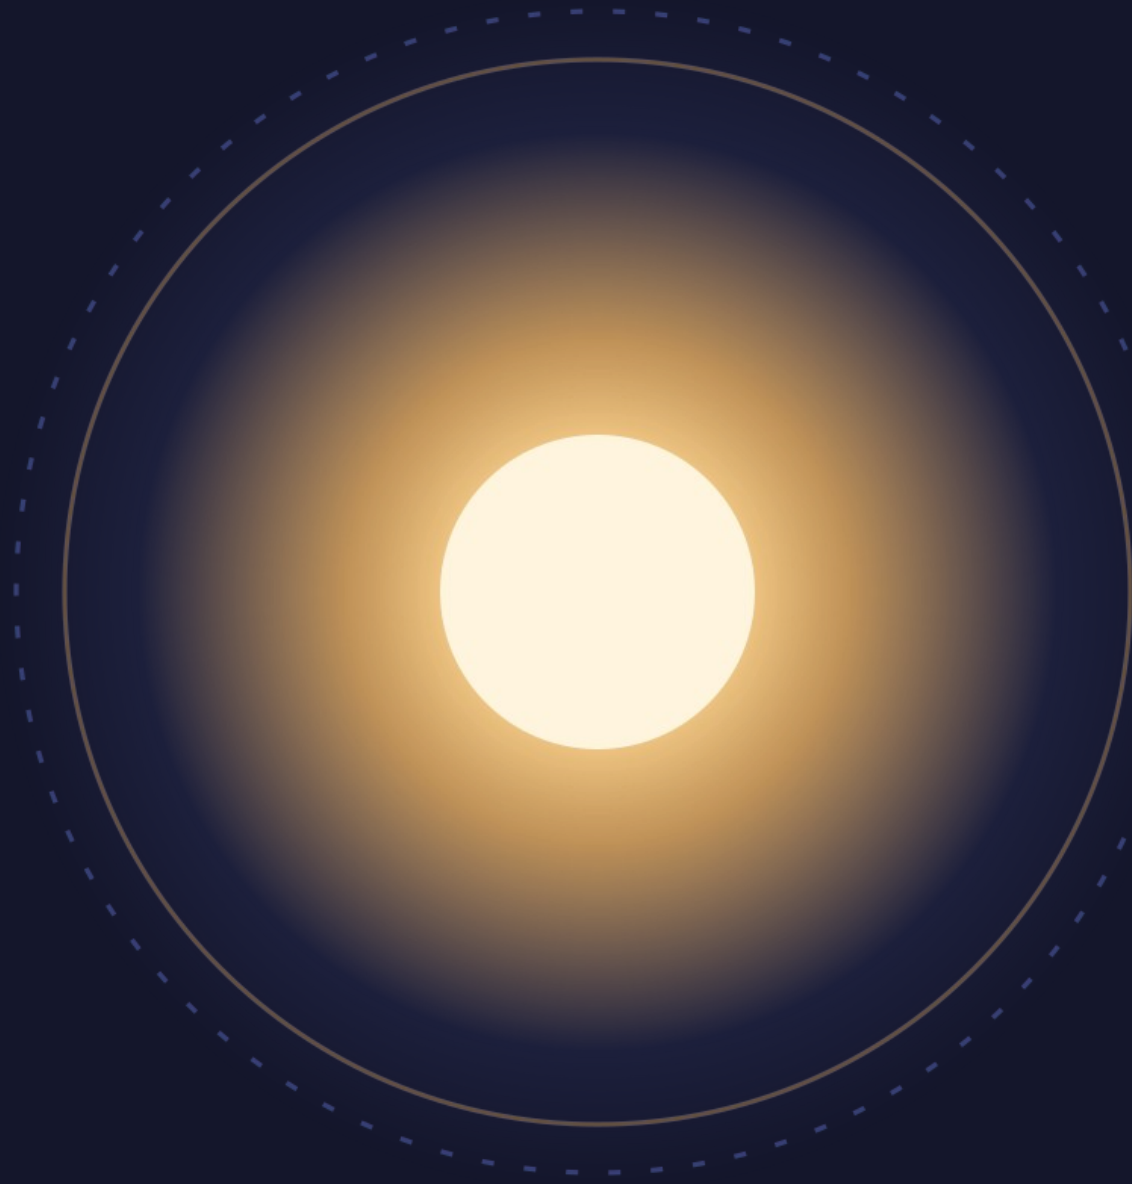
ТЕХНИЧЕСКАЯ ПРЕЗЕНТАЦИЯ

Lumo AI

Локальный ИИ-ассистент, который работает без интернета



Сурнова Варвара

ЗАДАЧА

Ассистент без облачного сервера

Проблема

Облачные ассистенты отправляют переписку на внешние серверы, не работают без сети и требуют подписки.

Цель

Запустить языковую модель прямо на ноутбуке и дать к ней удобный интерфейс с историей чатов.

Результат

Рабочее веб-приложение: три режима, картинки, сохранение чатов, полностью офлайн на MacBook Air M-серии.

ВОЗМОЖНОСТИ

Что умеет Lumo

Chat

Структурированные ответы: сначала коротко, потом по шагам

Write

Письма, посты и эссе с заданным тоном и длиной

Translate

Русский ↔ английский, только перевод

Картинки

Скриншот теста или задачи: модель читает и отвечает

История чатов

Чаты сохраняются, модель помнит 20 последних сообщений

Режим «Думать»

Модель рассуждает перед ответом: дольше, но логичнее

Офлайн

Ни одного внешнего запроса, даже шрифты системные

Два языка

Интерфейс на русском и английском, тёмная тема

АРХИТЕКТУРА

Три слоя, и все на одном компьютере



Ни один запрос не выходит за пределы ноутбука.

СТЕК

Технологии

Слой	Технология	Зачем
Языковая модель	Qwen3 8B	Хорошо понимает русский и английский, помещается в 16 ГБ памяти (≈5 ГБ на диске)
Модель для картинок	Qwen3-VL 8B	Читает текст и задания со скриншотов (≈6 ГБ на диске)
Запуск моделей	Ollama	Локальный сервер моделей с простым HTTP API, оптимизирован под Apple Silicon
Бэкенд	Python, FastAPI, Uvicorn	Асинхронный API, автоматическая документация /docs, проверка данных через Pydantic
HTTP-клиент	httpx	Асинхронные запросы к Ollama с таймаутом и обработкой ошибок
Хранилище	SQLite	Встроен в Python, не нужен отдельный сервер базы данных
Интерфейс	HTML, CSS, JavaScript	Без фреймворков и сборки, без внешних CDN: работает офлайн

ОБРАБОТКА ЗАПРОСА

Путь одного сообщения

1 Интерфейс

отправляет POST /chats/{id}/ask: текст, картинки и флаг think

2 Бэкенд

загружает из SQLite последние 20 сообщений чата

3 Бэкенд

добавляет промпт режима и выбирает модель: с картинкой — qwen3-vl

4 Ollama

генерирует ответ выбранной моделью

5 Бэкенд

сохраняет вопрос, картинки и ответ, задаёт название чата

6 Интерфейс

показывает ответ с форматированием Markdown

НАСТРОЙКА МОДЕЛИ

У каждого режима свой промпт и температура

Режим	Главное в системном промпте	Температура
Chat	Отвечать на языке пользователя, сначала коротко, потом по шагам; не выдумывать факты	0.4
Write	Соблюдать формат, тон и длину; возвращать только готовый текст	0.7
Translate	Русский → английский, остальное → русский; только перевод	0.1

Температура: ниже значит точнее и предсказуемее, выше значит разнообразнее.



Параметр think. Qwen3 умеет рассуждать перед ответом. По умолчанию это выключено ради скорости, а включается галочкой «Думать» в интерфейсе.

Две таблицы в SQLite

chats

```
id  INTEGER  PK
title  TEXT
mode  TEXT
created_at  TEXT
```

1:N

messages

```
id  INTEGER  PK
chat_id  →  chats.id
role  user | assistant
content  TEXT
images  TEXT (JSON)
created_at  TEXT
```

Картинки хранятся в base64 внутри сообщения. Файл lumo.db лежит в папке проекта и не попадает в Git. Название чата — первые 40 символов первого сообщения.

REST API

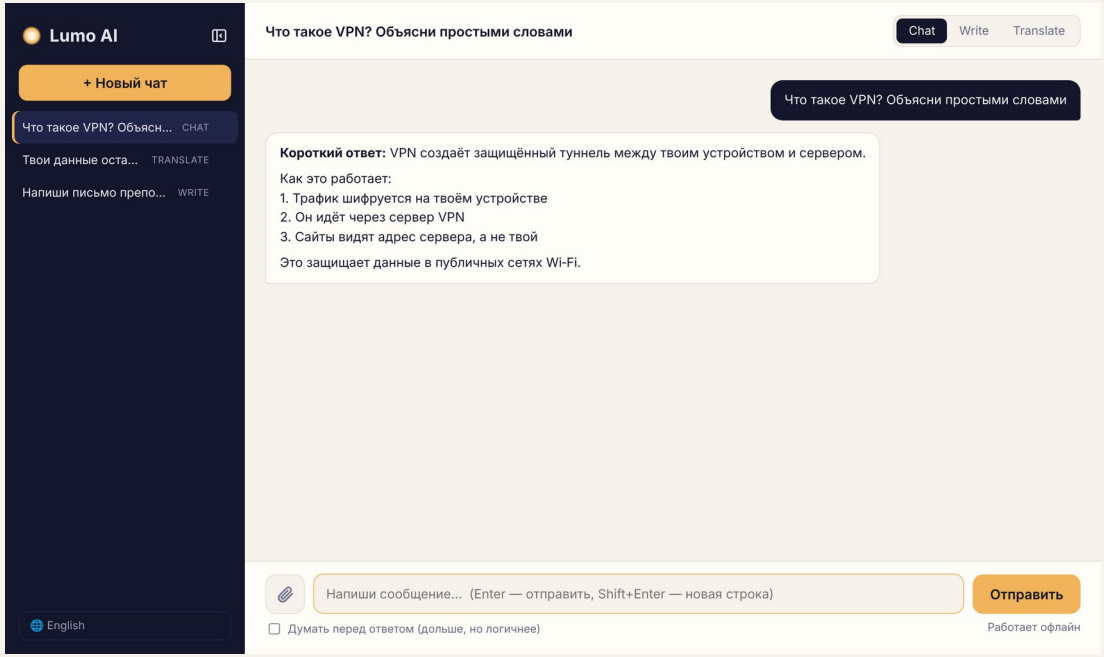
Эндпоинты бэкенда

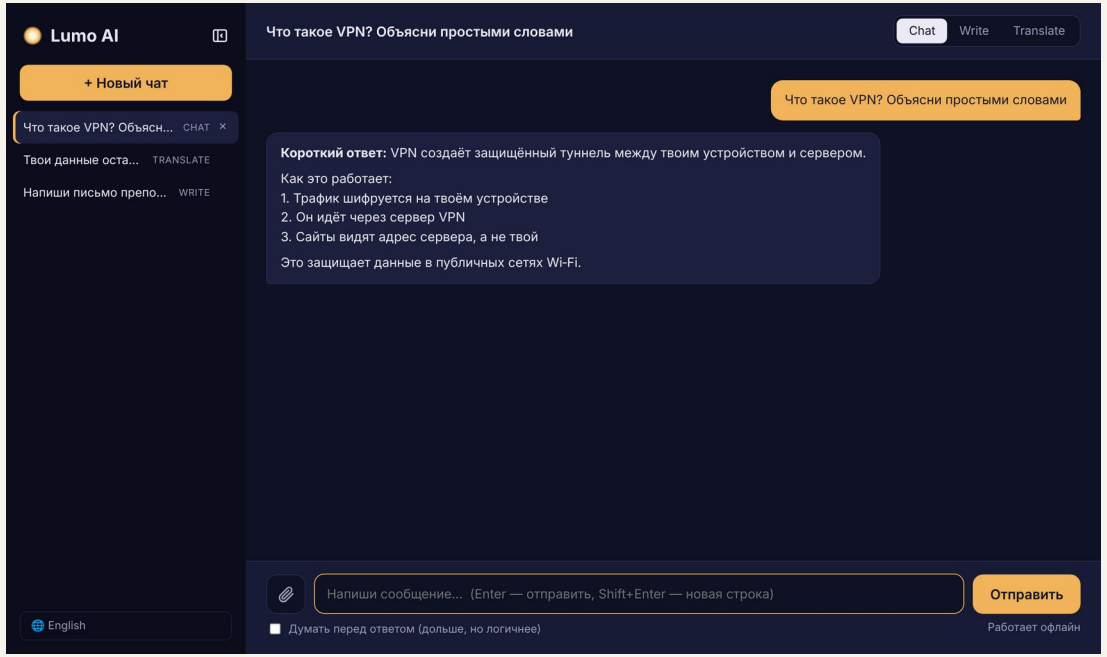
Метод	Путь	Назначение
POST	/ask	Разовый вопрос без сохранения
POST	/chats	Создать чат с выбранным режимом
GET	/chats	Список чатов
GET	/chats/{id}	Чат со всей историей
POST	/chats/{id}/ask	Сообщение в чат: текст, картинки, think
PATCH	/chats/{id}	Сменить режим чата
DELETE	/chats/{id}	Удалить чат

Интерактивная документация генерируется автоматически: http://127.0.0.1:8000/docs

ИНТЕРФЕЙС

Светлая и тёмная тема





- Список чатов, скрываемая боковая панель
- Режимы Chat / Write / Translate и прикрепление картинок
- Встроенный просмотр презентаций
- Русский и английский язык, тёмная тема, мобильная вёрстка

ТРЕБОВАНИЯ

На чём работает

16 ГБ

оперативной памяти: тестовый MacBook Air

≈11 ГБ

на диске: qwen3:8b (≈5) и qwen3-vl:8b (≈6)

0

внешних запросов во время работы

macOS на Apple Silicon, Python 3.9+, Ollama. Интернет нужен только для установки моделей и библиотек.

РАЗВИТИЕ

Планы



Потоковые ответы

Текст появляется по словам

Следующий шаг



Mac-приложение

Упаковка в Tauri



Свои документы

Локальный RAG по PDF и DOCX



Пароль

Доступ с других устройств



Спасибо за внимание!

Вопросы?