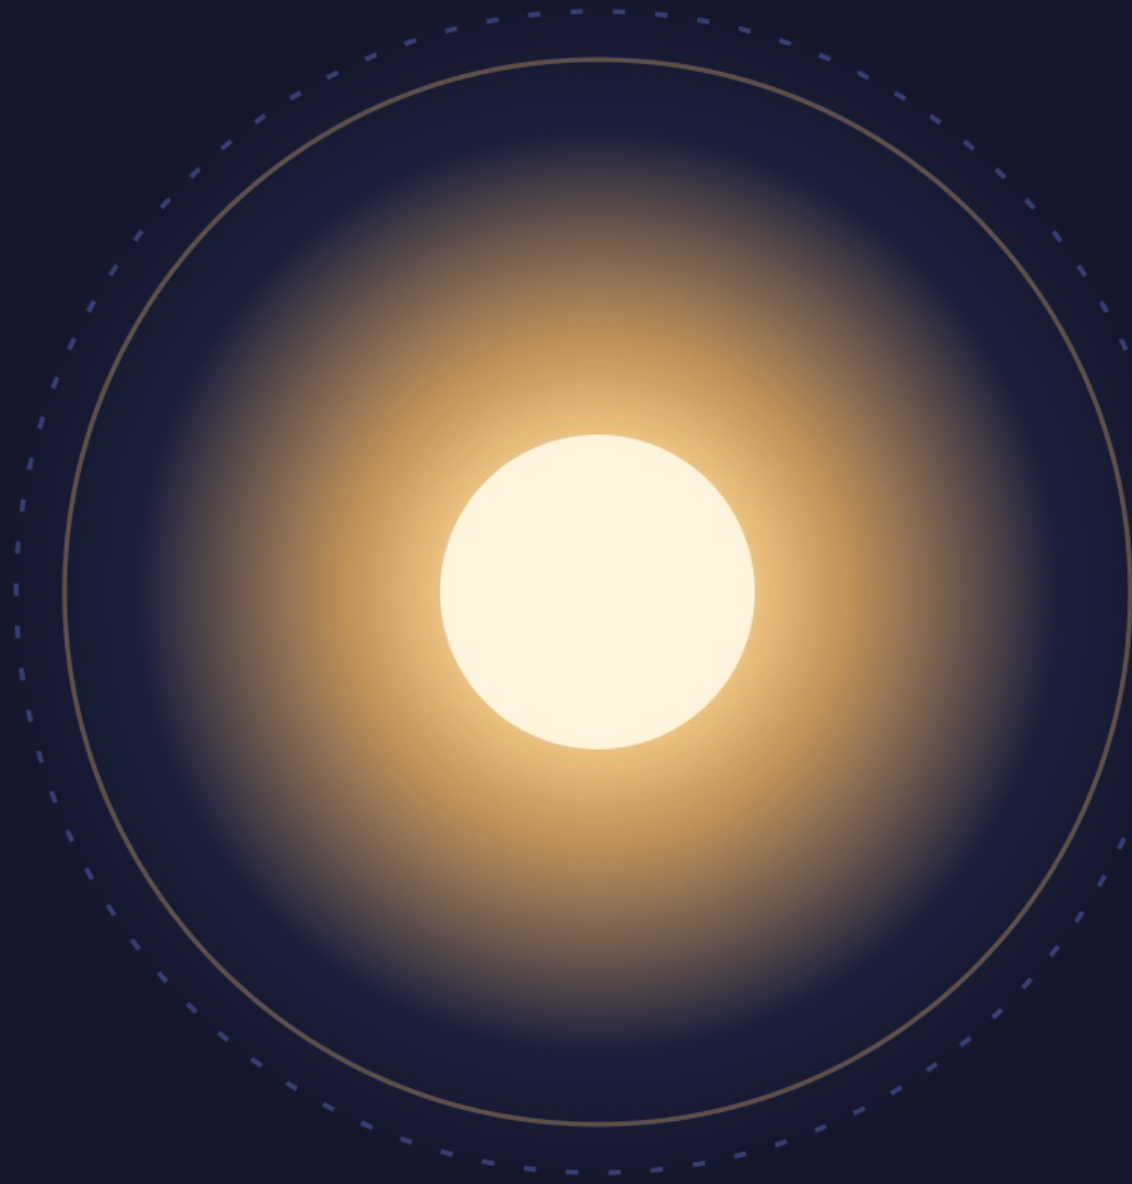
ТЕХНИЧЕСКАЯ ПРЕЗЕНТАЦИЯ

Lumo AI

Локальный ИИ-ассистент, который работает без интернета



Сурнова Варвара

ЗАДАЧА

Ассистент без облачного сервера

Проблема

Облачные ассистенты отправляют переписку на внешние серверы, не работают без сети и требуют подписки.

Цель

Запустить языковую модель прямо на ноутбуке и дать к ней удобный интерфейс с историей чатов.

Результат

Рабочее веб-приложение: три режима, сохранение чатов, полностью офлайн на MacBook Air M-серии.

ВОЗМОЖНОСТИ

Что умеет Lumo



Chat

Структурированные ответы: сначала коротко, потом по шагам



Write

Письма, посты и эссе с заданным тоном и длиной



Translate

Русский ↔ английский, только перевод



История чатов

Чаты сохраняются, модель помнит 20 последних сообщений



Режим «Думать»

Модель рассуждает перед ответом: дольше, но логичнее



Офлайн

Ни одного внешнего запроса, даже шрифты системные

АРХИТЕКТУРА

Три слоя, и все на одном компьютере



Ни один запрос не выходит за пределы ноутбука.

СТЕК

Технологии

Слой	Технология	Зачем
Языковая модель	Qwen3 8B	Хорошо понимает русский и английский, помещается в 16 ГБ памяти (≈5 ГБ на диске)
Запуск модели	Ollama	Локальный сервер моделей с простым HTTP API, оптимизирован под Apple Silicon
Бэкенд	Python, FastAPI, Uvicorn	Асинхронный API, автоматическая документация /docs, проверка данных через Pydantic
HTTP-клиент	httpx	Асинхронные запросы к Ollama с таймаутом и обработкой ошибок
Хранилище	SQLite	Встроен в Python, не нужен отдельный сервер базы данных
Интерфейс	HTML, CSS, JavaScript	Без фреймворков и сборки, без внешних CDN: работает офлайн

ОБРАБОТКА ЗАПРОСА

Путь одного сообщения

1 Интерфейс

отправляет POST /chats/{id}/ask с текстом и флагом think

2 Бэкенд

загружает из SQLite последние 20 сообщений чата

3 Бэкенд

добавляет системный промпт и температуру режима

4 Ollama

генерирует ответ моделью qwen3:8b

5 Бэкенд

сохраняет вопрос и ответ, задаёт название чата

6 Интерфейс

показывает ответ с форматированием Markdown

НАСТРОЙКА МОДЕЛИ

У каждого режима свой промпт и температура

Режим	Главное в системном промпте	Температура
Chat	Отвечать на языке пользователя, сначала коротко, потом по шагам; не выдумывать факты	0.4
Write	Соблюдать формат, тон и длину; возвращать только готовый текст	0.7
Translate	Русский → английский, остальное → русский; только перевод	0.1

Температура: ниже значит точнее и предсказуемее, выше значит разнообразнее.



Параметр think. Qwen3 умеет рассуждать перед ответом. По умолчанию это выключено ради скорости, а включается галочкой «Думать» в интерфейсе.

Две таблицы в SQLite

chats

```
id  INTEGER  PK
title  TEXT
mode  TEXT
created_at  TEXT
```



1:N

messages

```
id  INTEGER  PK
chat_id  →  chats.id
role  user | assistant
content  TEXT
created_at  TEXT
```

Файл lumo.db лежит в папке проекта и не попадает в Git (.gitignore). Название чата задаётся по первым 40 символам первого сообщения.

REST API

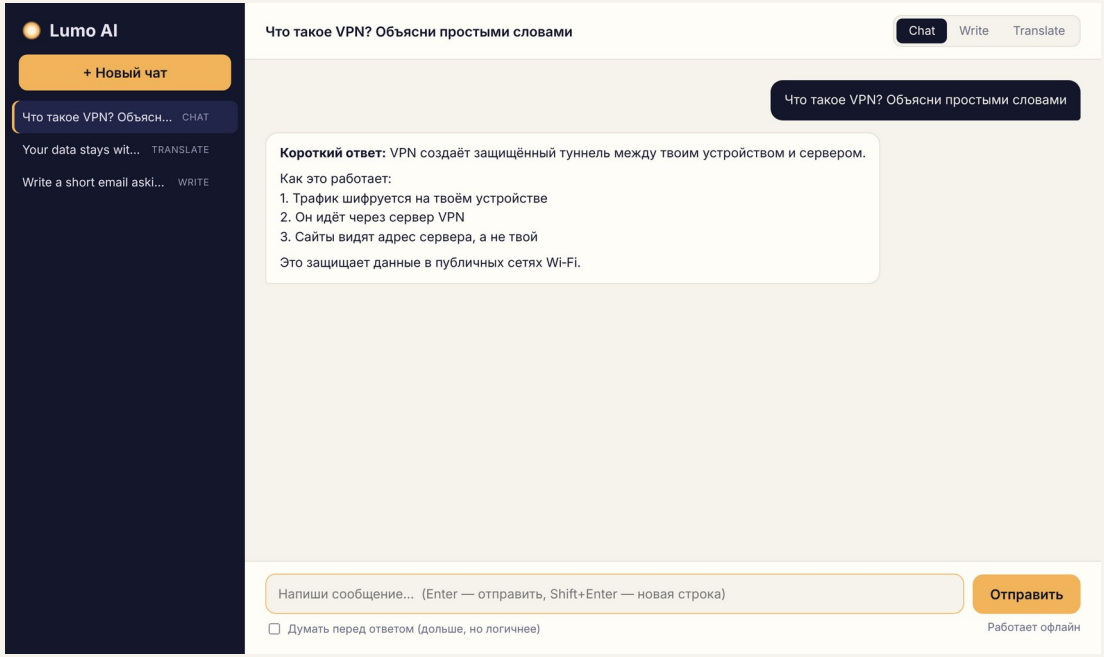
Эндпоинты бэкенда

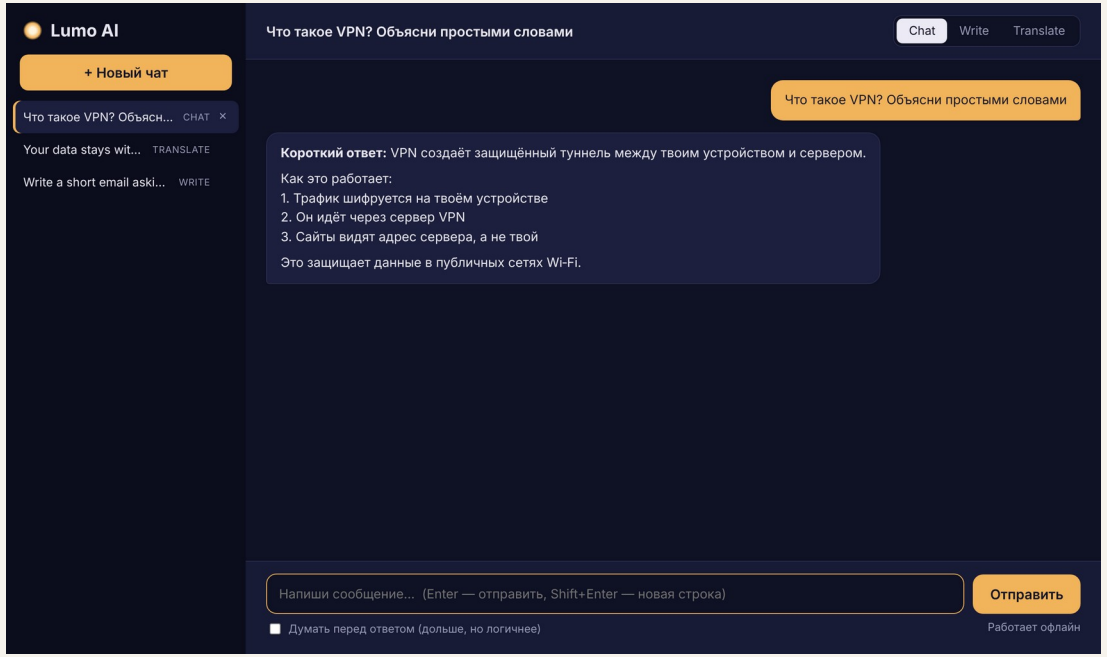
Метод	Путь	Назначение
POST	/ask	Разовый вопрос без сохранения
POST	/chats	Создать чат с выбранным режимом
GET	/chats	Список чатов
GET	/chats/{id}	Чат со всей историей
POST	/chats/{id}/ask	Сообщение в чат с учётом контекста
PATCH	/chats/{id}	Сменить режим чата
DELETE	/chats/{id}	Удалить чат

Интерактивная документация генерируется автоматически: http://127.0.0.1:8000/docs

ИНТЕРФЕЙС

Светлая и тёмная тема





- Список чатов и переключение между ними
- Переключатель режимов Chat / Write / Translate
- Markdown в ответах: списки, жирный текст, код
- Тёмная тема и мобильная вёрстка

ТРЕБОВАНИЯ

На чём работает

16 ГБ

оперативной памяти: тестовый MacBook Air

≈5 ГБ

занимает модель qwen3:8b на диске

0

внешних запросов во время работы

macOS на Apple Silicon, Python 3.9+, Ollama. Интернет нужен только для установки модели и библиотек.

РАЗВИТИЕ

Планы



Потоковые ответы

Текст появляется по словам

Следующий шаг



Приложение для Mac

Упаковка в Tauri



Свои документы

Локальный RAG по PDF и DOCX



Пароль

Доступ с других устройств



Спасибо за внимание!

Вопросы?