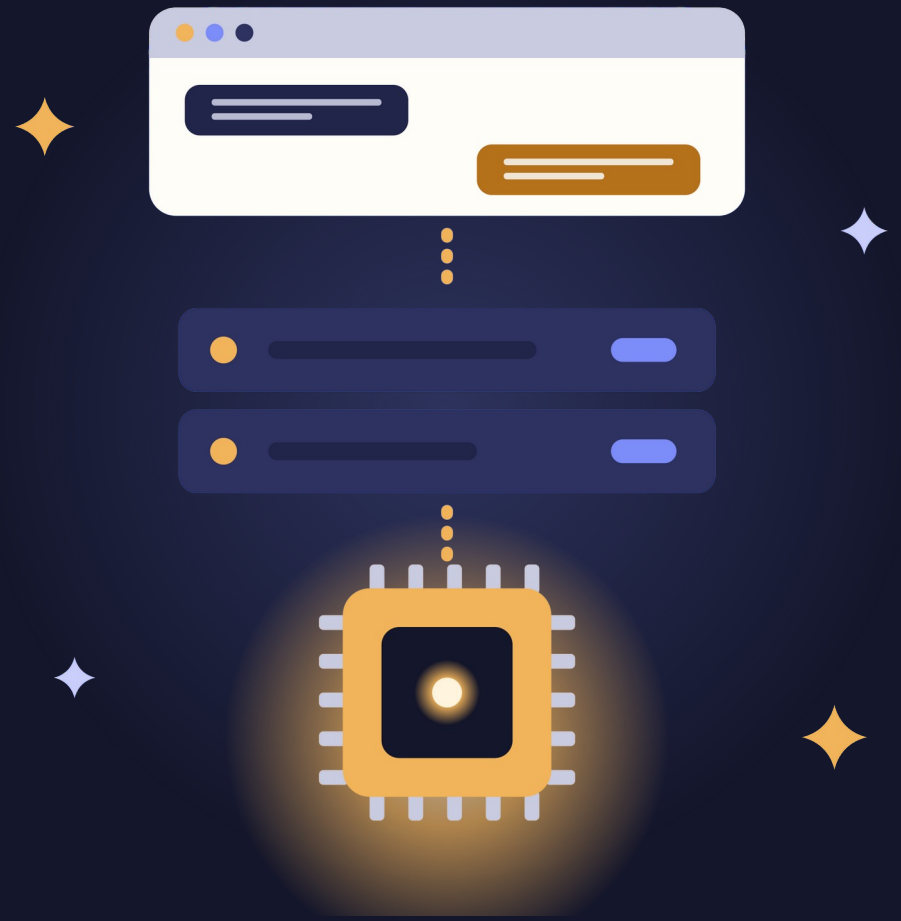
ТЕХНИЧЕСКАЯ ПРЕЗЕНТАЦИЯ

Lumo AI

Локальный ИИ без интернета



Сурнова Варвара

ЗАДАЧА

Ассистент без облака



ПРОБЛЕМА

Данные в облаке



ЦЕЛЬ

ИИ на ноутбуке



РЕЗУЛЬТАТ

Работает офлайн

ВОЗМОЖНОСТИ

Что умеет Lumo



Chat



Write



Translate



Картинки



История



«Думать»



Офлайн



RU / EN

АРХИТЕКТУРА

Три слоя на одном компьютере



СТЕК

Технологии

Qwen3 8B
текст

Qwen3-VL 8B
картинки

Ollama
запуск моделей

FastAPI
бэкенд

SQLite
история

HTML · CSS · JS
интерфейс

ОБРАБОТКА ЗАПРОСА

Путь одного сообщения



20 последних сообщений · промпт режима · qwen3 или qwen3-vl

НАСТРОЙКА МОДЕЛИ

Температура по режимам

Chat

0.4

точно

Write

0.7

живо

Translate

0.1

дословно



`think` — рассуждать перед ответом

Две таблицы в SQLite

chats

id
title
mode
created_at

1:N

messages

id
chat_id → chats
role
content
images
created_at

REST API

7 эндпоинтов

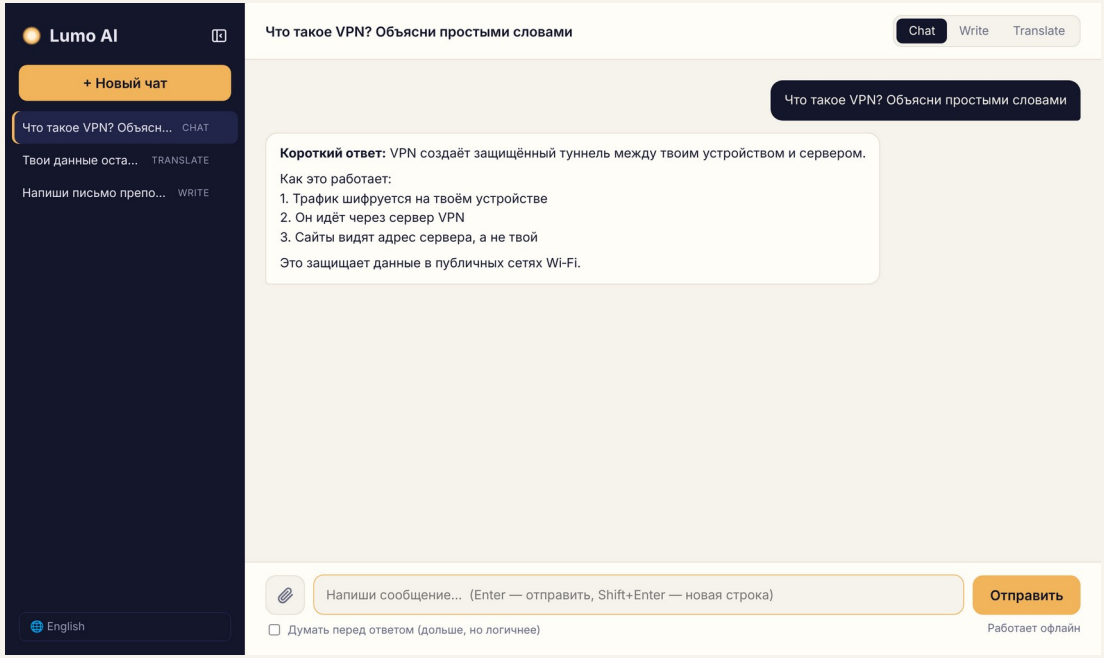
POST	/ask
POST	/chats
GET	/chats
GET	/chats/{id}
POST	/chats/{id}/ask
PATCH	/chats/{id}
DELETE	/chats/{id}



/docs

ИНТЕРФЕЙС

Светлая и тёмная тема





ТРЕБОВАНИЯ

На чём работает

16 ГБ RAM

11 ГБ на диске

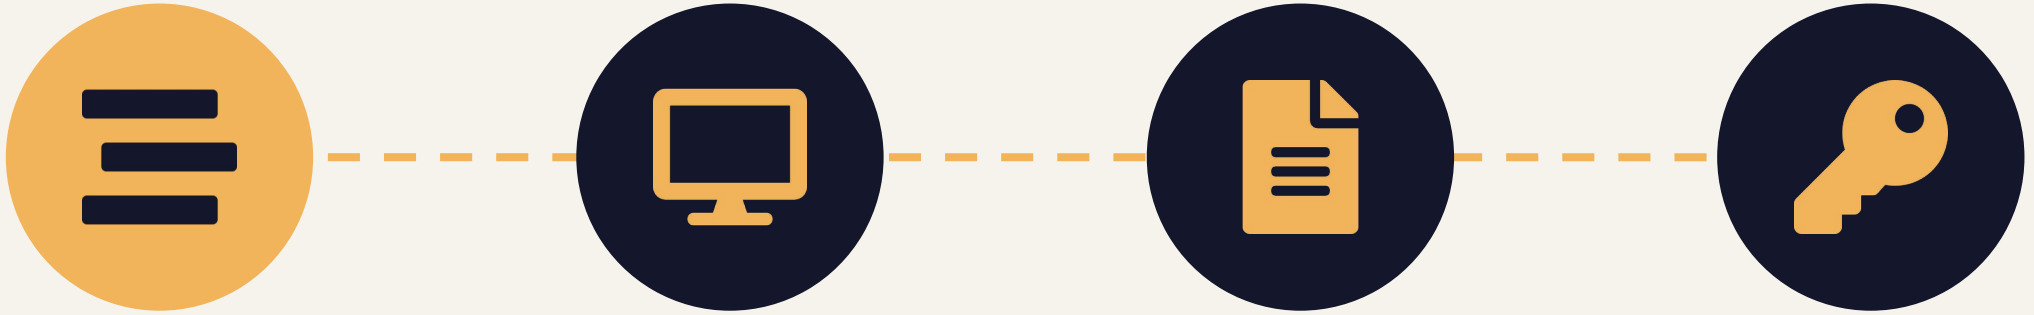
0 запросов в сеть



Windows · macOS · Linux

РАЗВИТИЕ

Планы



Потоковые ответы

Приложение для ПК

Свои документы

Пароль



Спасибо за внимание!

Вопросы?