技术介绍

Lumo AI

本地 AI，无需联网



Varvara Surnova

任务

不依赖云端的助手



问题

数据在云端



目标

AI 在笔记本上



成果

离线运行

功能

Lumo 能做什么



Chat



Write



Translate



Slides



Learn



图片



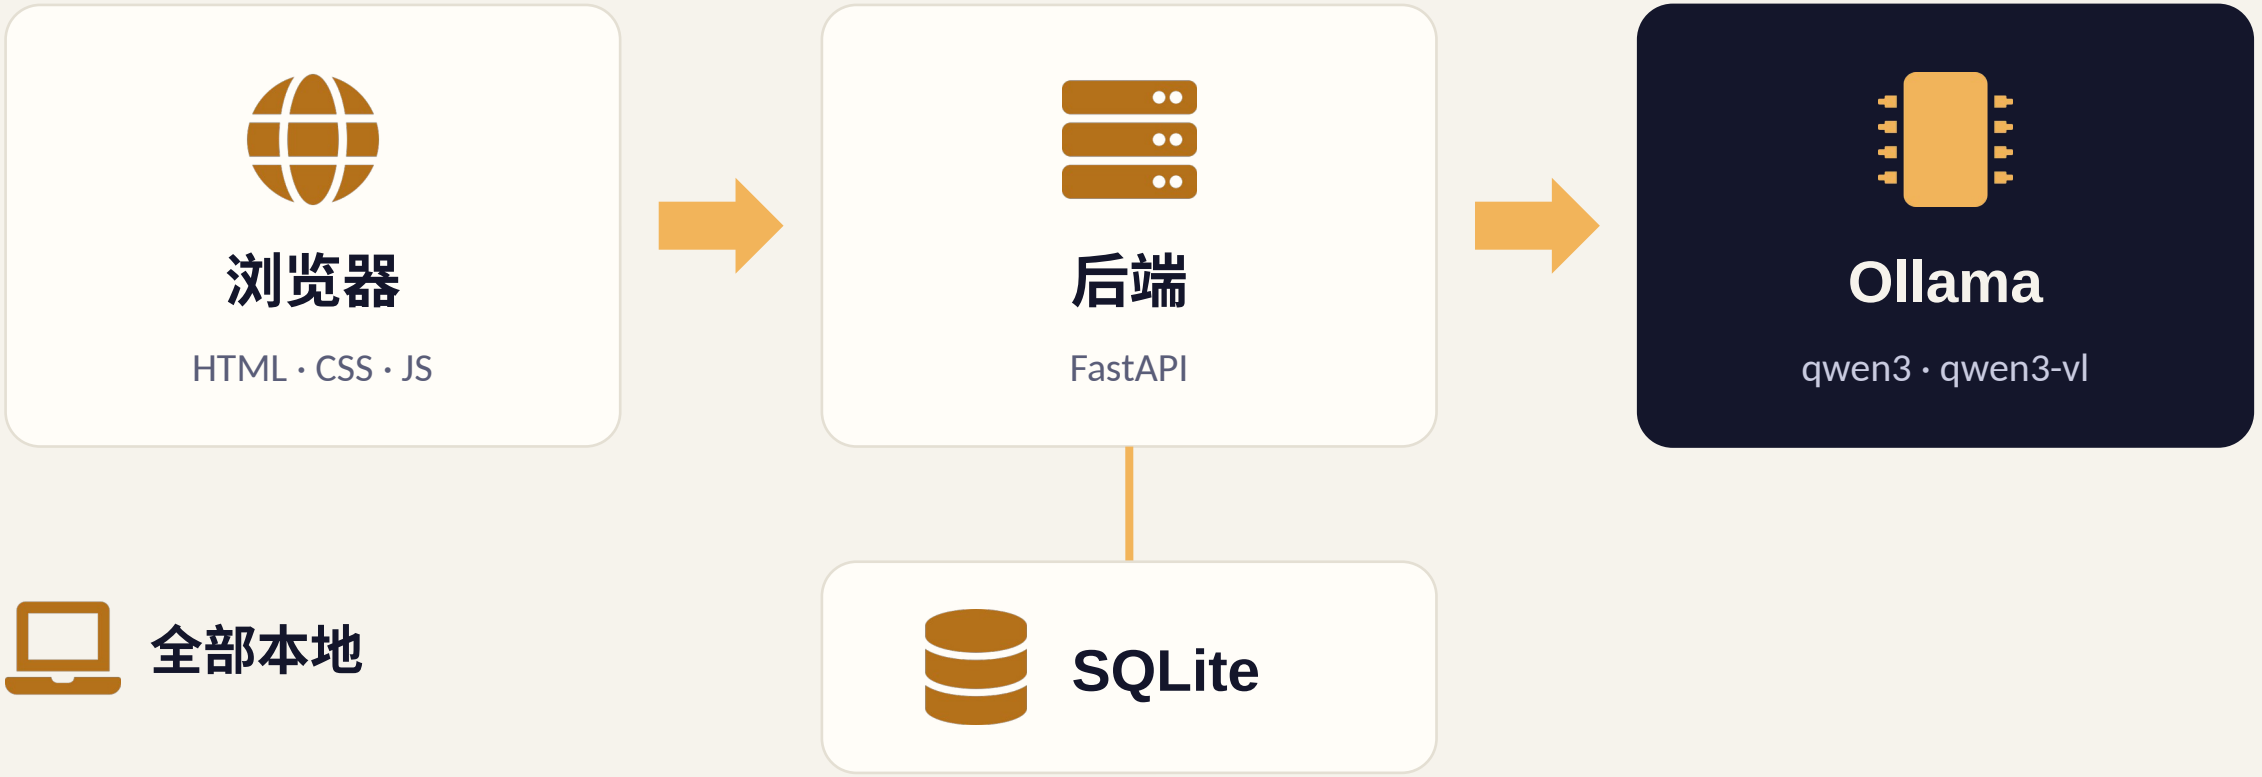
历史记录



5 种语言

架 构

三层结构，一台电脑



技 术 栈

技术

Qwen3 8B
文本

Qwen3-VL 8B
图片

Ollama
模型运行

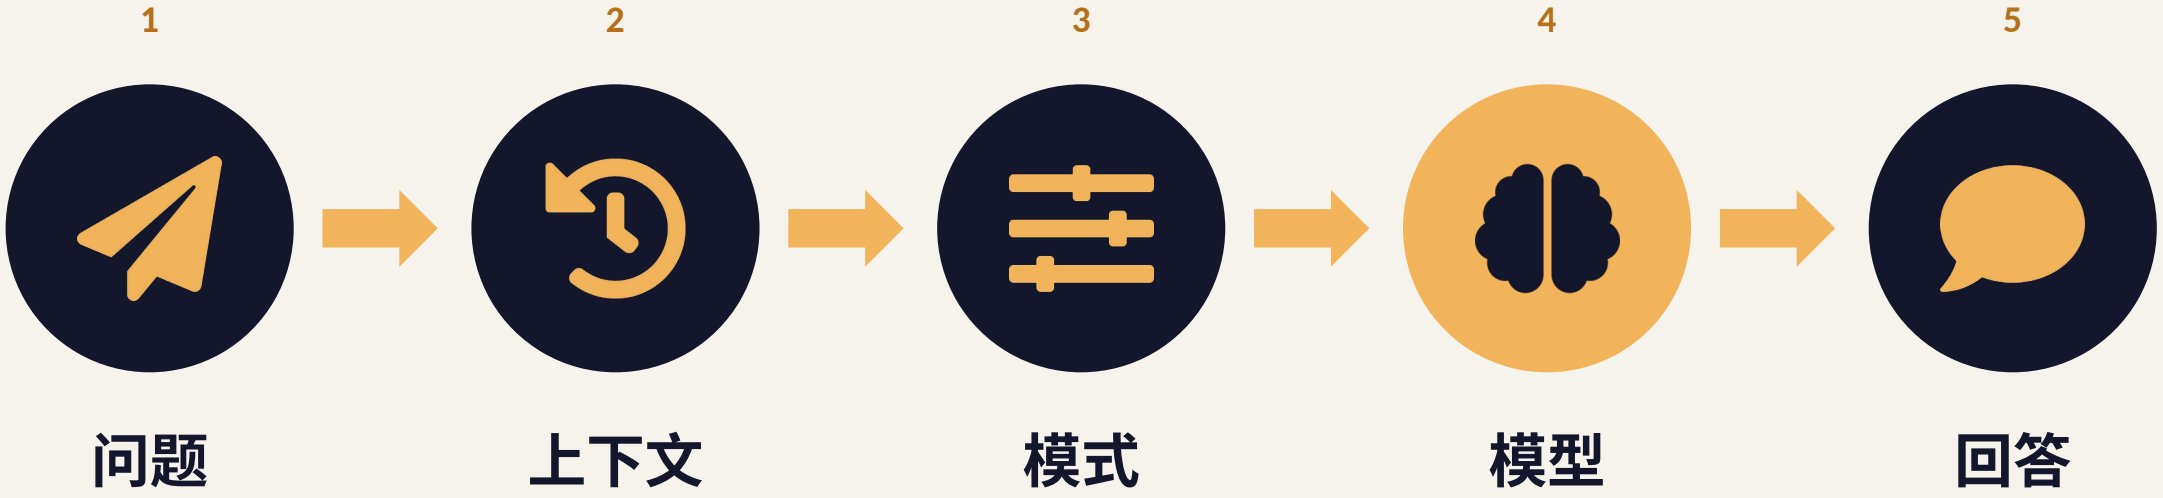
FastAPI
后端 · python-pptx

SQLite
历史记录

HTML · CSS · JS
界面

请求流程

一条消息的旅程



最近 20 条消息 · 模式提示词 · qwen3 或 qwen3-vl

模型设置

各模式的温度

Chat	Write	Translate	Slides	Learn
0.4	0.7	0.1	0.5	0.4
精确	生动	准确	有条理	均衡



`think` — 先推理再回答

SQLite 中的两张表

chats

id
title
mode
created_at

1:N

messages

id
chat_id → chats
role
content
images
created_at

REST API

8 个接口

POST	/ask
POST	/chats/{id}/ask
POST	/chats
PATCH	/chats/{id}
GET	/chats
DELETE	/chats/{id}
GET	/chats/{id}
GET	/decks/{file}

/docs

界 面

浅色和深色主题

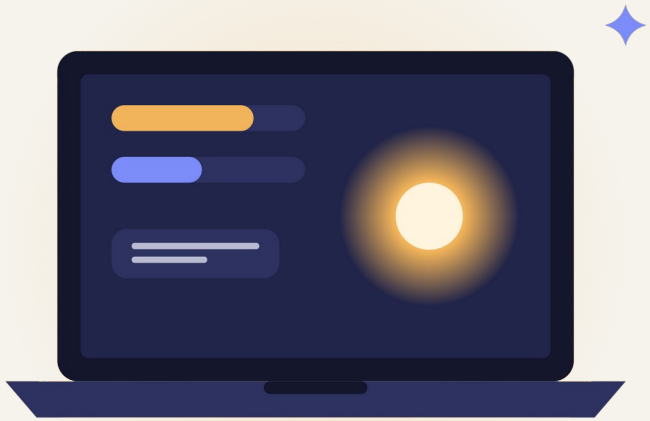

Lumo AI
+ 新对话
什么是 VPN？请用简单的... CHAT
你的数据只属于你 TRANSLATE
测一下我的英语水平 LEARN
中文
什么是 VPN？请用简单的话解释
Chat
Write
Translate
Slides
Learn
什么是 VPN？请用简单的话解释
简短回答： VPN 在你的设备和服务器之间建立一条加密通道。
工作原理：
1. 流量在你的设备上加密
2. 通过 VPN 服务器传输
3. 网站看到的是服务器的地址，而不是你的
这样即使在公共 Wi-Fi 上，你的数据也是安全的。
输入消息...（Enter 发送，Shift+Enter 换行）
发送
先思考再回答（更慢，但更有条理）
离线运行


Lumo AI
+ 新对话
什么是 VPN？请用简单的... CHAT
你的数据只属于你 TRANSLATE
测一下我的英语水平 LEARN
中文
什么是 VPN？请用简单的话解释
Chat
Write
Translate
Slides
Learn
什么是 VPN？请用简单的话解释
简短回答： VPN 在你的设备和服务器之间建立一条加密通道。
工作原理：
1. 流量在你的设备上加密
2. 通过 VPN 服务器传输
3. 网站看到的是服务器的地址，而不是你的
这样即使在公共 Wi-Fi 上，你的数据也是安全的。
输入消息...（Enter 发送，Shift+Enter 换行）
发送
先思考再回答（更慢，但更有条理）
离线运行

运行要求

运行环境

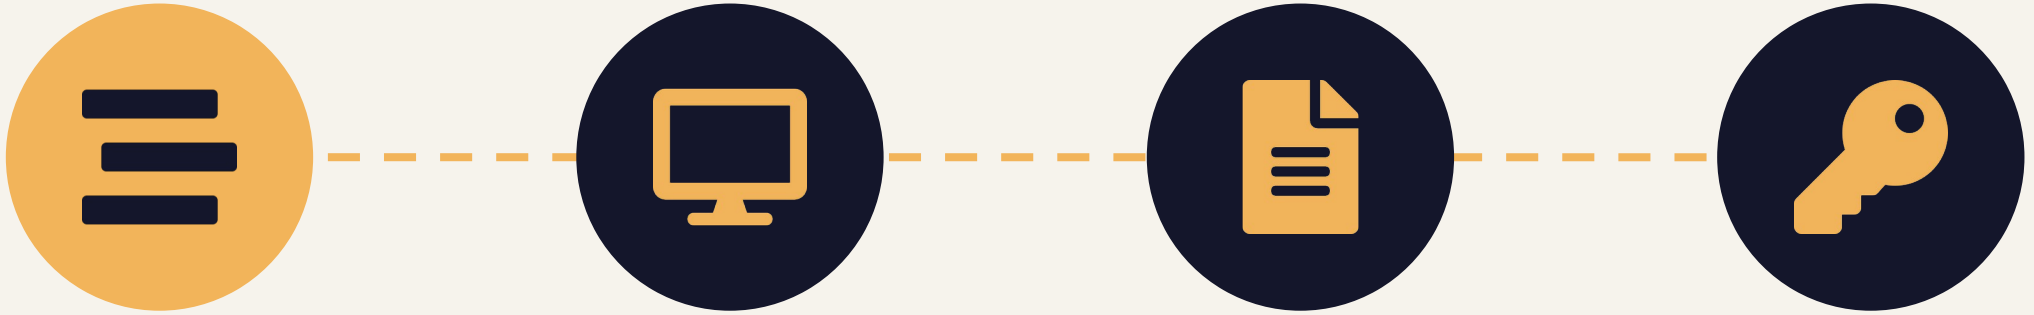
16 GB	11 GB	0
内存	磁盘空间	次联网请求



Windows · macOS · Linux

路线图

计划



流式输出

桌面应用

你的文档

密码



感谢聆听！

有问题吗？